

Guía de Actividades Práctico-Experimentales Nro. 014

Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Grupo	G
Integrantes	- Emerson Chamba - Matias Labanda - Lenin Macas - Pilar Naranjo - Mateo Pucha
Unidad	3
Resultado de aprendizaje de la unidad	Comprende los conceptos de variable aleatoria multidimensional y distribución de probabilidad asociada, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	014
Título de la Práctica	Modelado Probabilístico Avanzado: Regresión Logística, Clasificación Binaria y Matriz de Confusión
Nombre del Docente	Cristian Ramiro Narváez Guillén
Fecha	Martes 20 de julio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

1. Objetivo(s) de la Práctica:

-
- Construir modelos probabilísticos para variables de respuesta binaria utilizando la Función Sigmoide y la Estimación de Máxima Verosimilitud (MLE) a través de statsmodels y scikit-learn.
- Aplicar el modelo de regresión logística al conjunto de datos regional del Proyecto Integrador para predecir la probabilidad de que ocurra un evento de interés, evaluando su precisión empírica (ABP).
- Investigar y demostrar computacionalmente el efecto de modificar el umbral de decisión probabilística (cutoff) sobre las tasas de Error Tipo I y Tipo II mediante el análisis de la Matriz de Confusión (ABI).

2. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x]

3. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología

Enfoque PID-2025:

- ABP (Aprendizaje Basado en Problemas): El estudiante descubrirá que predecir el comportamiento de su región usando una sola variable (Semana 13) es impreciso. Deberá combinar múltiples factores (ej. temperatura, humedad y altitud para predecir rendimiento agrícola) y decidir si vale la pena la complejidad adicional del modelo.
- ABI (Aprendizaje Basado en Investigación): Indagación sobre el "castigo matemático" que aplica el R^2 Ajustado cuando se añaden variables "basura" al modelo, y cómo descubrir si dos predictores están compitiendo entre sí (Multicolinealidad).
- Duración sugerida: 120 min. (presencial).
- Modalidad: Ejecución técnica individual con consolidación del modelo final para el Proyecto Integrador en grupos.

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante ya no predice un valor continuo (ej. →cuánto lloverá"), sino la probabilidad de ocurrencia de una condición crítica (ej. "¿Habrá inundación? 1=Sí, 0=No"). Deberá transformar un problema de su región en una pregunta de clasificación binaria.
- **ABI (Aprendizaje Basado en Investigación) :** Indagacion matematica sobrepor qué OLS (Mínimos Cuadrados Ordinarios) falla estrepitosamente al predecir categorías, obligando a la introducción de la

función Sigmoide y el pseudo- R^2 .

- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual, con interpretación y ajuste de umbrales en los grupos del Proyecto Integrador.

Tarea 1: Fundamentos de la Regresión Logística (Función Sigmoide)

A diferencia de la regresión lineal, la regresión logística estima la probabilidad $P(Y = 1|X)$. Para garantizar que el resultado esté estrictamente acotado entre $[0, 1]$, se utiliza la función logística (Sigmoide):

1.

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}}$$

Abra un nuevo Jupyter Notebook llamado APE_015_Logistica.ipynb.

2. Escenario: Predecir la Caída de un Servidor (1 = Sí, 0 = No) basándonos en la Temperatura de la CPU en °C (X_1).

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.api as sm
```

```
# 1. Generación de datos simulados (Clasificación Binaria)
np.random.seed(42)
n_muestras = 200
```

```
# Variable predictora: Temperatura CPU (entre 40 y 90 grados)
temp_cpu = np.random.uniform(40, 90, size=n_muestras)
```

```
# Generar variable binaria probabilística (A mayor temperatura, mayor probabilidad de falla)
```

```
z = -10 + 0.15 * temp_cpu # Ecuación lineal (Log-Odds)
probabilidad_falla = 1 / (1 + np.exp(-z)) # Transformación Sigmoide

# Variable respuesta binaria (0 = OK, 1 = Falla) basada en la probabilidad
falla_servidor = np.random.binomial(1, p=probabilidad_falla)

df_sim = pd.DataFrame({'Temp_CPU': temp_cpu, 'Falla': falla_servidor})

# 2. Ajuste del Modelo Logístico (Logit)
X_log = sm.add_constant(df_sim['Temp_CPU'])
Y_log = df_sim['Falla']

# Entrenamiento usando MLE (Maximum Likelihood Estimation) modelo_lo-
git = sm.Logit(Y_log, X_log).fit()

print(modelo_logit.summary())

# 3. Visualización de la Curva Sigmoide x_ran-
go = np.linspace(30, 100, 300) x_rango_sm =
sm.add_constant(x_rango)
y_pred_prob = modelo_logit.predict(x_rango_sm)

plt.figure(figsize=(8, 5))
sns.scatterplot(x='Temp_CPU', y='Falla', data=df_sim, color='black', alpha=0.5, la-
bel='Datos (0 o 1)')
plt.plot(x_rango, y_pred_prob, color='red', linewidth=2, label='Curva de
Probabilidad Logística')
plt.axhline(0.5, color='gray', linestyle='--', label='Umbral de Decisión (50%)') plt.ti-
tle('Regresión Logística: Probabilidad de Falla vs Temperatura') plt.xlabel('Tem-
peratura CPU (°C)')
plt.ylabel('Probabilidad de Falla P(Y=1)') plt.le-
gend()
plt.show()
```

Tarea 2: Hito del Proyecto - Predicción Dicotómica Regional (ABP)

1. Importe su dataset regional mediante pandas.
2. Ingeniería de Características: Seleccione una variable continua de inte-
rés y binarícela.

- ~~Emp~~ Si tiene "Ingresos", cree una nueva columna Alta_Rentabilidad donde **1** si Ingresos > Promedio, y **0** si Ingresos $\leq$ Promedio.

3. Seleccione al menos dos variables predictoras (X_1, X_2) para predecir esta nueva variable binaria.
4. Ajuste el modelo sm.Logit() e imprima el resumen.
5. Interprete los resultados: ¿Qué variable(s) incrementa(n) estadísticamente la probabilidad de que ocurra su evento (coeficiente positivo y valor-p < 0.05)?

Tarea 3: Evaluación del Modelo (Matriz de Confusión)

Un modelo de clasificación no se evalúa con el R^2 , sino contando cuántos aciertos y errores cometió.

1. Utilice scikit-learn para calcular las predicciones y generar la Matriz de Confusión del modelo simulado en la Tarea 1.

```
from sklearn.metrics import confusion_matrix, accuracy_score,  
ConfusionMatrixDisplay
```

```
# El modelo devuelve probabilidades continuas [0, 1]. Debemos convertirlas a  
0 o 1
```

```
# usando un umbral (threshold) estándar de 0.5 (50%)  
probabilidades = modelo_logit.predict(X_log) prediccio-  
nes_clase = (probabilidades >= 0.5).astype(int)
```

```
# Cálculo de la Matriz de Confusión
```

```
cm = confusion_matrix(Y_log, predicciones_clase) exacti-  
tud = accuracy_score(Y_log, predicciones_clase)
```

```
print(f"\n--- Evaluación del Modelo Probabilístico ---")  
print(f"Exactitud Global (Accuracy): {exactitud*100:.2f}%")
```

```
# Visualización
```

```
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=['OK (0)',  
'Falla (1)'])  
disp.plot(cmap='Blues', values_format='d')
```



unl

Universidad
Nacional
de Loja

FEIRNNR - Carrera de Computación

plt.title('Matriz de Confusión (Umbral 0.5)')

plt.show()

Apique el mismo proceso para evaluar el modelo de su Proyecto Integrador.

Tarea 4: ABI - El Análisis del Umbral (Thresholding) y Falsos Positivos

Por defecto, Python asume que si $P(Y = 1) \geq 0.50$, la clasificación es 1. Sin embargo, en ingeniería, el costo de un "Falso Negativo" (predecir que el servidor no fallará y que termine explotando) suele ser mucho mayor que un "Falso Positivo" (ir a revisar un servidor que estaba bien).

1. Investigue cómo alterar el umbral modifica la Matriz de Confusión.
2. Cree un bloque de código que recalcule y muestre la matriz de confusión (o simplemente los valores de Falsos Positivos y Falsos Negativos) utilizando un umbral estricto conservador del 0.20 (es decir, clasificar como 'Falla' si la probabilidad es apenas $\geq 20\%$).
3. Redacte un análisis de qué le sucedió a los Falsos Positivos frente a los Falsos Negativos, y decida qué umbral (0.50 o 0.20) recomendaría para las políticas públicas o de ingeniería en su proyecto regional.

5. Resultados esperados:

Al finalizar esta práctica, el estudiante será capaz de:

- Interpretar la relación no lineal entre variables independientes y la probabilidad de un evento dicotómico mediante la función sigmoide.
- Justificar la elección de un umbral de decisión (cutoff) basado en el análisis de costos y beneficios (Falsos Positivos vs. Falsos Negativos).
- Evaluar críticamente la robustez de un modelo probabilístico utilizando la matriz de confusión.
- Traducir coeficientes estadísticos (Log-Odds) en decisiones de ingeniería informadas.

6. Preguntas de Control:

- **¿Cuál es la esencia matemática de transformar una probabilidad en Log-Odds, y por qué este cambio de dominio es fundamental para el entendimiento de la causalidad probabilística?**

La probabilidad P está acotada entre 0 y 1. La función Log-Odds ($\ln(P / (1 - P))$) transforma este intervalo al dominio continuo $(-\infty, +\infty)$. Este cambio es fundamental porque permite relacionar linealmente los predictores X con el logaritmo de la ventaja y asegurar que, al aplicar la función Sigmoide, las probabilidades predichas siempre se mantengan en el rango válido de $[0, 1]$.

- **¿Por qué la naturaleza del fenómeno (binario) nos obliga a abandonar la medida clásica de bondad de ajuste (R^2) y adoptar el Pseudo R^2 de McFadden, y qué nos dice este cambio sobre la relación entre la realidad y la medición?**

El R^2 tradicional mide la varianza explicada en variables continuas mediante suma de errores cuadráticos. Con respuestas binarias (0/1), la varianza no es constante y la noción de distancia cuadrática falla. El Pseudo R^2 de McFadden compara la log-verosimilitud del modelo completo frente a un modelo nulo, evaluando la capacidad del sistema para maximizar la probabilidad conjunta de los eventos observados en lugar de medir distancias.

- **Ante un caso de incertidumbre total (predicción 0.5), ¿de qué manera la estructura del modelo intenta forzar una decisión binaria, y qué riesgos enfrentamos al ignorar la zona gris de la probabilidad?**

El modelo fuerza la decisión aplicando un umbral rígido de corte (p. ej., $\geq 0.5 \rightarrow 1$ y $< 0.5 \rightarrow 0$). El riesgo de ignorar la $\rightarrow$ zona gris $\rightarrow$ es tomar decisiones drásticas e irreversibles basadas en variaciones aleatorias mínimas (como 0.499 vs 0.501), tratando situaciones de máxima incertidumbre como certidumbres absolutas.

- **¿Cuál es el conflicto esencial entre la sensibilidad y la especificidad, y cómo la elección de un umbral refleja los valores éticos y técnicos subyacentes en una decisión de ingeniería?**

Existe un conflicto directo: al bajar el umbral para aumentar la Sensibilidad (detectar más verdaderos positivos), disminuye la Especificidad y aumentan los Falsos Positivos. En ingeniería y políticas públicas, el umbral se elige evaluando los costos asimétricos: si omitir un caso crítico (Falso Negativo) pone en riesgo la salud pública o la infraestructura, la ética técnica exige bajar el umbral (p. ej., a 0.20) para priorizar la detección.

- **¿Cuál es el propósito final de predecir probabilidades en lugar de estados binarios rígidos, y cómo esta distinción transforma nuestra capacidad de intervenir en la realidad?**

Permite evaluar el nivel continuo de riesgo en lugar de dar una respuesta categórica y rígida. Predecir probabilidades transforma la toma de decisiones, permitiendo a los ingenieros planificar de forma preventiva, establecer prioridades de atención y optimizar presupuestos antes de que ocurra una crisis o falla en el sistema.

7. Conclusiones.

- La regresión logística mediante la transformación Logit y la función Sigmoide demostró ser la herramienta adecuada para abordar problemas de respuesta binaria, superando las limitaciones del modelo lineal OLS y permitiendo modelar la probabilidad de déficit básico en la provincia de Loja en un rango acotado entre 0 y 1.
- Se evidenció que la fuerte correlación entre las variables predictoras (Poblacion y Viviendas) limita la significancia estadística individual de los coeficientes ($P > |z|$), lo que resalta la necesidad de transformar o seleccionar adecuadamente los predictores para evitar la redundancia de información en modelos probabilísticos.
- La reducción del umbral de decisión probabilística del 0.50 al 0.20 demostró que es posible eliminar los Falsos Negativos a costa de un ligero incremento en los Falsos Positivos, lo cual resulta técnicamente recomendado en políticas públicas para priorizar la atención de cantones vulnerables y evitar la omisión de necesidades críticas.

8. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio	Puntaje	Descripción
Implementación Técnica	3.0 pts	Ejecución correcta del modelo (simulado y regional) y limpieza/documentación del código.
Análisis y Diagnóstico	5.0 pts	Interpretación de coeficientes, diagnóstico efectivo de multicolinealidad (VIF) y visualización.



Reflexión Crítica	2.0 pts	Calidad y profundidad en las respuestas a las preguntas de control (enfoque aristotélico).
Total	10.0 pts	

9. Bibliografía

Liste las fuentes utilizadas. Use normas IEEE. Pueden ser libros, manuales, artículos, tutoriales académicos, documentación oficial de software.

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "→scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].

10. ANEXOS

Link colab: <https://colab.research.google.com/drive/1itRbUiltG6qtAEOiTUE9CF5GKIS-TrWgO?usp=sharing>

11. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	